

# Wi-Fi チャンネル状態情報を用いた屋内日常物の状態推定

尾原 和也<sup>1</sup> 前川 卓也<sup>1</sup> 松下 康之<sup>1</sup>

**概要：**ドアや窓の開閉のような屋内日常物の状態を推定する手法の研究がこれまでに盛んにわれてきた。これまでの研究ではドアや窓などのそれぞれの日常物にセンサを設置する手法が多く取られていたが、日常物の数に応じたセンサが必要となるため、設置・管理コストが大きくなる。そこで本研究では、環境内に市販の Wi-Fi 電波送受信機を 1 台ずつ設置し、受信機で得られる Wi-Fi 電波の伝搬情報を用いることで日常物の状態変化を検知する手法を提案する。日常物の操作による電波伝搬の変化を捉えるため、本研究では Wi-Fi 電波の伝搬情報として、各送受信アンテナ間のマルチパス情報が含まれる Wi-Fi チャンネル状態情報 (CSI) を利用する。環境内には様々な物体が存在するため、提案手法では独立成分分析を用いて各日常物の状態変化による CSI への影響を分離する。また、CSI は伝搬損失や反射等の様々な情報を含んでいるため、直感的に特徴量を設計することは困難である。そこで、Deep Neural Network によって特徴量を自動的に抽出し、隠れマルコフモデル (HMM) によって各時刻における日常物の状態を推定する。加えて日常物の事前知識に基づいた文法を用いて HMM の状態遷移を制限し、精度の向上を試みる。

**キーワード：**日常物の状態変化検知, Wi-Fi チャンネル状態情報, 深層学習, 隠れマルコフモデル

## 1. はじめに

ドアや窓の開閉のような屋内日常物の状態変化を検知する手法の研究がこれまでに盛んに行われてきた。日常物の状態変化の検知は、人の侵入を検知する防犯システムや空調、照明の制御のようなホームオートメーション、高齢者の見守り等の幅広い分野への応用が期待できる。これまでの研究ではドアや窓などのそれぞれの日常物に加速度センサやジャイロセンサ、振動センサ、スイッチセンサを設置し、無線通信によって情報を集約することで実現されてきた [1], [2], [3]。しかし、これらの手法は日常物それぞれにセンサを設置する必要があるため、バッテリーの交換やセンサ故障時の取り替え等の点で手間がかかるため、導入・管理コストが大きいという問題がある。

そこで本研究では、ドアや窓等の屋内日常物それぞれにセンサを設置せずに、環境 (部屋) 内に市販の Wi-Fi アクセスポイント (AP) と Wi-Fi モジュールを搭載したコンピュータを 1 台ずつ設置し、コンピュータから得られる Wi-Fi 電波の伝搬情報のみを用いることで日常物の開閉といった状態変化を検知する手法を提案する。本研究で想定する環境を図 1 に示す。Wi-Fi 電波はドア等の日常物によって反射するため、日常物の状態が変化することで電波の反射の仕方が変化し、Wi-Fi 電波の伝搬情報に変化が

生じる。特に本研究では伝搬情報として、送受信アンテナ間のマルチパス情報が得られる Wi-Fi チャンネル状態情報 (Channel State Information: CSI) を用いる。

Wi-Fi 電波は伝搬損失や反射・回折等のマルチパスの影響によって振幅と位相が変化する。CSI はこれらの影響による電波の振幅と位相の変化をそれぞれ複素数の絶対値と偏角で表す。Wi-Fi 802.11 の物理層から得られる情報である。近年では Intel 5300 等の Network Interface Card (NIC) によって CSI が得られるようになったため、CSI を用いた屋内位置推定、行動認識の研究が多数行われている。

Wi-Fi の規格である 802.11a/g/n では直交周波数分割多重方式 (Orthogonal Frequency Division Multiplexing: OFDM) を用いてデータを変調している。OFDM はデータを周波数が異なった複数のサブキャリア (搬送波) に乗せる方法で、それぞれのサブキャリアの周波数は高速フーリエ変換によって分けられるように互いに直交する。さらに、802.11n では複数の送受信アンテナを用いる Multiple Input and Multiple Output (MIMO) という技術が使われている。各サブキャリアは周波数が異なるため、その減衰や反射の仕方が異なり、各送受信アンテナ間では異なった伝搬路によって電波が送られるため、各送受信アンテナ間の各サブキャリアごとに異なった振幅変化と位相変化が起こる。すなわち CSI は送信アンテナ数を  $N_T$ 、受信アンテナ数を  $N_R$ 、サブキャリア数を  $N_S$  とすると、 $N_T \times N_R \times N_S$  次

<sup>1</sup> 大阪大学大学院情報科学研究科




図 1 想定環境

Fig. 1 Assumed environment

元のデータとして Wi-Fi パケットごとに得られる。Wi-Fi による通信を繰り返し行えば、CSI は高次元の時系列データとなる。

Wi-Fi 電波は送信電力の変化や環境の変化、他の電波の干渉等の多くのノイズを含んでおり、CSI データからノイズを除去する必要がある。既存の CSI を用いたコンテキスト認識に関する研究ではノイズの除去を行うために、異なるサブキャリアや送受信アンテナ間のデータを統合することで、伝搬路や周波数に依存しない CSI の変化を用いている。Ali らは各送受信アンテナ間の  $N_S$  次元のデータに対して主成分分析 (Principal Component Analysis: PCA) を行い、CSI を  $N_T \times N_R$  次元に削減している [4]。Chapre らはサブキャリアごとに  $N_T \times N_R$  次元のデータを加算し、そこから位相と振幅を抽出している [5]。しかし、このような手法を用いると伝搬路やサブキャリアに依存した CSI の各次元のデータの小さな変化を捉えることが難しくなる。CSI を用いたいくつかの研究では Wi-Fi 機器の近く、もしくは送受信機の間にあるものを観測対象としているが、本研究の対象となるドアや窓等の日常物は屋内の離れた場所に位置するため、日常物ごとに影響が大きい伝搬路や周波数は異なると考えられ、ノイズ除去と共に各日常物による影響を分離する必要がある。

そこで本研究では CSI データに対して独立成分分析 (Independent Component Analysis: ICA) を行う。ICA はブラインド音源分離や脳波のノイズ除去に用いられる手法で、複数の信号源からの信号が混ざったデータが複数の観測器によって観測されるとき、信号が互いに独立であるという仮定を用いて各信号源の信号に分離する手法である。本研究において、各日常物の電波状態への影響は独立であると仮定すると、各送受信アンテナの組を観測器としてみなせ、CSI の  $N_T \times N_R$  次元のデータに対して ICA を行うことで、各日常物の操作によって生じた CSI の変化やノイズ成分に分離できると考えられる。

また、これまでの多くの屋内位置推定、行動認識の研究では機械学習を用いたパターン認識を行うことが多いが、CSI データは電波の反射や回折、伝搬損失などの複合的な影響を反映する情報であり、他のセンサデータと異

なり有用と思われる特徴抽出方法を研究者が設計することは困難である。そこで本研究では画像認識や音声認識の分野で大きな成果を上げている Deep Neural Network (DNN) を用いることで、CSI の時系列データから特徴量を自動抽出する。本研究で用いる DNN は畳み込みニューラルネットワーク (Convolutional Neural Network: CNN) [6] と Long-Short-Term Memory (LSTM) [7] から構成される。CNN では学習によって最適化されたフィルタを用いて入力されたデータを畳み込むことで、有用な特徴を自動的に抽出することができる。LSTM は時系列データの学習に用いられるリカレントニューラルネットワーク (Recurrent Neural Network: RNN) を長期の依存関係も学習できるように拡張したモデルである。Ordóñez ら [8] はウェアラブルセンサで得られる時系列データを時間窓ごとに CNN と LSTM からなる DNN に入力することで各時刻の行動を高い精度で分類している。本研究でも同様に CSI データを時間窓で分割し、時間窓ごと CNN を適用し、CNN の出力を LSTM の入力とすることで、時間窓ごとに日常物の状態推定を行う。ここで CSI の各伝搬路や周波数のデータには相関があるとされている [4] ため、本研究では各要素を連結し時系列順に並べることで行列化した CSI の時系列データに対して時系列方向と伝搬路・周波数方向の 2 次元のフィルタを用いて畳み込み演算を行う。

上記の CNN と LSTM からなる DNN は時間窓ごとに日常物の状態を推定する。しかし、日常物の状態は時間窓ごとに独立しておらず、日常物の時系列的な状態変化を捉える必要がある。そこで、本研究では時系列データの学習に用いられる生成モデルである隠れマルコフモデル (Hidden Markov Model: HMM) [9] を用いて時系列性を考慮し精度向上を目指す。具体的には、LSTM の最終時刻の出力を特徴量として HMM の入力とし、HMM の出力を最終的な推定結果とする。これにより、DNN による特徴量の自動抽出を行ったうえで、状態変化の時系列性を考慮した認識が可能となる。

さらに、状態推定の精度を向上させるために、日常物の事前知識に基づいて構築した文法を利用する。事前知識に基づいて構築した文法とは、例えばドアの場合、ドアを「開ける動作」は「閉じている状態」からのみ遷移し、「開ける動作」の後は「開いている状態」に必ず遷移するといったものである。各日常物に関してこのような文法を作成し、HMM デコーディングに用いる Viterbi アルゴリズムで利用する。

## 2. 関連研究

### 2.1 屋内日常物の開閉状態変化検知

各日常物にスイッチセンサや RFID タグ、振動センサ、加速度センサといった小型のセンサを取り付けた屋内日常物の開閉状態変化検知の研究は数多く行われてきた [1], [2], [3]。

このような手法は日常生活をきめ細やかに観測できるが、バッテリーの交換等の必要があるため、導入・管理コストが大きい。この問題に対処するため、Campbell らはビルの監視を行うためのエナジーハーベスティングセンサを提案している [10]。提案されたセンサでは、太陽光等で生み出した電力によってピエゾフィルム振動センサが振動を検知したことを伝えるパケットを送出する。このセンサをドアや窓等に設置すると開閉を検知することができる。

気圧計によってドアの開閉を検知する研究も行われている。Patel らは、空調のフィルタに気圧計を設置することでドアの開閉によって起こる気圧の変化を検知している [11]。Wu らは、空調システムが導入されているビルにおいてドアを開いたときに起こる気圧の大きな変化をスマートフォンの気圧計を用いて検知している [12]。

ドアにセンサを直接添付しない手法として Shi らは、環境の変化によって FM 電波の状態が変化することを用いて、FM 電波受信器で「空部屋」、「ドアが開いている」、「人が歩いている」という状況を識別している [13]。一方で、本研究では、市販されている Wi-Fi のアクセスポイントと Wi-Fi モジュールによって得られる CSI を用いることで、ドアや窓等の日常物の開閉状態変化を検知する。

## 2.2 Wi-Fi の受信電波強度を用いたコンテキスト認識

Wi-Fi による無線 LAN 通信の普及によって、多くの研究者が Wi-Fi の受信電波強度 (Received Signal Strength Indicator: RSSI) を用いた人の行動認識の研究を行っている。Sigg らはスマートフォンを Wi-Fi の受信器とした行動認識を行っている [14]。一般的な Android スマートフォンは 1Hz 程度のサンプリングレートでしか RSSI を取得できず、行動認識に利用することが難しいため、Wi-Fi のドライバを修正し、Wi-Fi パケットごとに RSSI を取得できるようにしている。Abdelnasser らはスマートフォン等の Wi-Fi 機器を胸の前に置くことで呼吸の間隔とパターンを監視し、呼吸停止等の検出を行っている [15]。

## 2.3 CSI を用いたコンテキスト認識

RSSI の値は反射等のマルチパスの影響で変化しやすく、パケットごとに統合された実数のスカラー値であるため、RSSI から伝搬路の状態を正確に計測するのは難しいとされている [16]。一方で、CSI は 1 つのパケットから多次元のデータが得られ、各送受信アンテナで得られた各サブキャリアの振幅と位相の情報を含んだデータであるため、RSSI より詳細な環境の情報が得られ、CSI を用いた行動認識の研究が盛んに行われている。

### 2.3.1 Wi-Fi チャンネル状態情報

CSI は Wi-Fi 通信における物理層で抽出される送受信機間の伝搬路の状態を表す情報として知られている。CSI は送信された電波の伝搬損失や反射・回折等のマルチパスの

影響による振幅変化、位相変化を表し、OFDM における互いに直交した異なる周波数を持つサブキャリアごとに得られる。\$\mathbf{x}\_i\$ と \$\mathbf{y}\_i\$ をそれぞれ \$i\$ 番目のサブキャリアで得られる \$N\_T\$ 次元の送信ベクトルと \$N\_R\$ 次元の受信ベクトルとするとそれらの関係は次式で表せる。

$$\mathbf{y}_i = \mathbf{H}_i \mathbf{x}_i + \mathbf{n}_i \quad (1)$$

ここで \$\mathbf{n}\_i\$ は \$N\_R\$ 次元のノイズベクトルであり、\$\mathbf{H}\_i\$ は \$i\$ 番目のサブキャリアで得られる \$N\_R \times N\_T\$ 次元の行列である。\$\mathbf{H}\_i\$ は \$i\$ 番目のサブキャリアで得られる CSI であり、次式で表せる。

$$\mathbf{H}_i = \begin{bmatrix} h_{11} & h_{12} & \cdots & h_{1N_T} \\ h_{21} & h_{22} & \cdots & h_{2N_T} \\ \vdots & \vdots & \ddots & \vdots \\ h_{N_R1} & h_{N_R2} & \cdots & h_{N_RN_T} \end{bmatrix} \quad (2)$$

ここで \$h\_{mn}\$ は \$m\$ 番目の受信アンテナと \$n\$ 番目の送信アンテナ間の伝搬路における CSI の値である。\$h\_{mn}\$ は複素数であり、次式で表される。

$$h_{mn} = ||h_{mn}|| e^{j\angle h_{mn}} \quad (3)$$

\$||h\_{mn}||\$ は CSI の振幅であり、\$\angle h\_{mn}\$ は CSI の位相である。

### 2.3.2 CSI を利用した行動認識

Wang らは CSI を入力とする多クラス SVM によって単純な行動を識別している [17]。[18] では、CSI の変化と人の動く速度の関係をモデル化し、人の部位ごとの速度と行動との関係のモデルを HMM によって構築している。

CSI を用いた高齢者見守りの研究として転倒検知の研究が多く行われている。WiFall では、CSI の時間的変化を用いて様々な環境で転倒検知を行っている [19]。Anti-Fall では、転倒時と転倒に似た行動における CSI の位相と振幅の違いからそれらを識別している [20]。

Liu らは呼吸のリズムと関連のあるパターンを CSI から抽出することで、呼吸等のユーザの睡眠情報を捉えることを試みている [21]。Ali らはキーストロークにおいて、CSI の時系列データから各キーを入力したときの特徴を抽出することによってどのキーが押されたかを識別している [4]。

## 2.4 DNN を用いた行動認識

Zeng らは手首に装着した 3 軸の加速度センサの時系列データに対して、1 層の畳み込み層と 2 層の全結合層からなる DNN を用いることで行動認識を実現している [22]。Opportunity [23] 等の行動認識用のデータセットに対して DNN による分類精度の評価を行っている。Yang らは 4 層の畳み込み層と 1 層の全結合層からなる DNN を用いて Opportunity 等のデータセットの評価を行っている [24]。Ordóñez らは 3 軸の加速度センサの時系列データに対して、3 層の畳み込み層を持つ CNN と 2 層の LSTM からな




図 2 提案手法の概要

Fig. 2 Overview of proposed method

る DNN を用いており、Zeng らと同様のデータセットによって評価を行っている [8]。センサデータは 113 チャンネルあるが、それらは観測する軸が異なっていたり別の位置に装着されたセンサであるため、時間方向に対してのみ 1 次元の畳み込みを行っている。

本研究では CSI データを Ordóñez らと同様の 3 層の畳み込み層を持つ CNN と 2 層の LSTM からなる DNN に入力することで特徴量を自動で抽出する。ただし CSI データは伝搬路や周波数ごとに相関がみられるため、CNN では 2 次元の畳み込みを行う。

### 3. 提案手法

#### 3.1 提案手法の概要

提案手法の概要を図 2 に示す。提案手法では各時刻における各日常物の状態を日常物ごと独立して推定する。提案手法では、まず CSI の振幅成分と位相成分を ICA によって独立成分に分離する。そして、CSI の振幅成分、位相成分、振幅の独立成分、位相の独立成分を時間窓ごと DNN に入力し、屋内日常物の状態推定に有用な特徴量を抽出する。最後に特徴量を HMM に入力し、各屋内日常物が各時刻において「開く動作中（開動作）」、「閉じる動作中（閉動作）」、「開いている状態（開状態）」、「閉じている状態（閉状態）」のいずれであるかを推定する。

#### 3.2 ICA による独立成分分離

ICA は信号源の情報を用いずに、複数の信号源からの信号が混ざったデータを信号が統計的に互いに独立であるという仮定を用いて各信号源からの信号に分離する方法である。ICA では、時刻  $t$  の信号源からの信号ベクトルを  $\mathbf{s}(t) = [s_1(t), s_2(t), \dots, s_M(t)]^T$ 、観測された信号ベクトルを  $\mathbf{x}(t) = [x_1(t), x_2(t), \dots, x_M(t)]^T$  としたとき、 $\mathbf{x}(t)$  が  $\mathbf{s}(t)$  の線形和

$$\mathbf{x}(t) = \mathbf{A}\mathbf{s}(t) \quad (4)$$

で表されるモデルを想定する。 $\mathbf{A}$  は  $M \times M$  次元の混合行列である。このとき、ICA の目的は  $\mathbf{A}$  に関する情報を持たずに、次式で表される分離行列  $\mathbf{W}$  を計算することで  $\mathbf{s}(t)$  を求めることである。

$$\mathbf{s}(t) = \mathbf{W}\mathbf{x}(t) \quad (5)$$

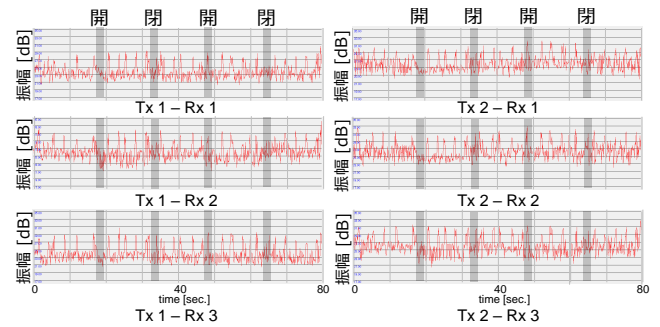


図 3 ドアを開閉したときの CSI のあるサブキャリアにおける振幅の時系列データ

Fig. 3 CSI amplitude time-series for a certain subcarrier obtained when we open and close door




図 4 ドアを開閉したときの CSI のあるサブキャリアにおける振幅の独立成分の時系列データ

Fig. 4 Independent component time-series of CSI amplitude for a certain subcarrier obtained when we open and close door

$\mathbf{W}$  を計算するために  $\mathbf{s}(t)$  の各要素は統計的に互いに独立であることを仮定する。本研究では各屋内日常物による Wi-Fi 電波の反射は独立であると仮定し、各送受信アンテナの組を観測器としてみなすことで、CSI の振幅成分と位相成分を各屋内日常物による反射の影響に分離する。本研究では  $\mathbf{W}$  を計算するために FastICA[25] を用いる。

ICA では観測器の数より多い信号源からの信号を分離することはできないため、提案手法では各日常物が操作された区間のデータに対し ICA を行うことで、日常物ごとに  $\mathbf{W}$  を計算する。注目している日常物の「開動作」と「閉動作」とラベル付けされた区間の振幅、もしくは位相の時系列データをトレーニングデータから抽出し、サブキャリアごとに  $N_T \times N_R$  次元のデータに対して FastICA を行い、 $\mathbf{W}$  を計算する。そして  $\mathbf{W}$  を用いて CSI の振幅、位相の時系列データを独立成分に分離する。

ドアを開閉したときのあるサブキャリアの振幅の時系列データと ICA による独立成分の分離を行った時系列データの例をそれぞれ図 3 と図 4 に示す。送信アンテナ数  $N_T = 2$ 、受信アンテナ数  $N_R = 3$  であるため、6 次元の時系列データが示されている。図 3 ではどの時系列データもドアを開閉したときに大きな変化が見られないが、図 4 の






図 5 CSI に対する畳み込み演算

Fig. 5 Convolution for CSI

独立成分 1 では開閉時に大きな変化が見られる。

### 3.3 DNN による特徴抽出

DNN による特徴抽出では、CSI 時系列データを時間窓によって分割し、時間窓ごとに有用な特徴量を抽出する。本研究で用いる DNN は 3 層から成る CNN と 2 層の LSTM から構成される。まず、各時刻において CSI の振幅成分の各要素をベクトル化し、時刻順に並べることで  $(N_T N_R N_S) \times T$  次元の行列を作成する。ここで  $T$  は時間窓内のサンプル数である。CSI の位相成分、振幅の独立成分、位相の独立成分においても同様に行列を作成する。CNN では作成した四つの行列に対しそれぞれ 2 次元の畳み込み演算を行う。

ICA では、分離された独立成分の順序に曖昧性が存在し、注目している日常物の影響をどの独立成分が反映しているかを定めることができない。そこで振幅の独立成分、位相の独立成分について時間方向に畳み込み演算を行うとともに、まず独立成分に対して畳み込み演算を行い、有用な独立成分を抽出する。また各伝搬路や各サブキャリアで得られる CSI の値には互いに相関があると言われているため、その後サブキャリアに対しても畳み込み演算を行うことで相関を利用した次元削減、特徴抽出を行う。CSI の振幅、位相についても同様に時間方向に畳み込み演算を行うとともに、伝搬路に対して畳み込み演算を行い、その後周波数に対して畳み込み演算を行う。CSI に対する畳み込み演算の概要を図 5 に示す。また、CNN においてバッチ正規化 [26] を行う。バッチ正規化では CNN の各出力をバッチごとと正規化することで、出力値が発散することを抑制し、学習速度が向上する。

LSTM では CNN の出力を時刻ごとに入力し、時系列性を考慮した特徴抽出を行う。LSTM では各時刻の出力を次の時刻に入力することで時系列性を考慮するため、時間窓内において最も情報が集約された最終時刻の出力を HMM に入力する特徴量とする。

DNN の学習時には、最終層に softmax 層を追加する。softmax 層では各時刻ごと LSTM の出力を入力とし、「開動作」、「閉動作」、「開状態」、「閉状態」の各状態のクラス分類確率を出力する。このクラス分類確率と正答の間の交




図 6 実験環境

Fig. 6 Experimental environment

差エントロピーを最小化することで DNN のパラメータを学習する。最適化手法には Adam[27] を用い、過学習を防ぐために Dropout[28] を用いる。

本研究では、CNN の各層のフィルタ数を 32、LSTM の各層のユニット数を 128 としている。そのため、DNN によって抽出される特徴量として各時間窓から 128 次元のベクトルが得られる。

### 3.4 HMM による状態推定

#### 3.4.1 生成モデルの構築

各時間窓の LSTM の出力を日常物の動作と状態ごと用意した left-to-right の HMM の出力 (観測) とし、Baum-Welch アルゴリズム [9] によって各 HMM のパラメータを学習する。HMM の出力分布には Gaussian Mixture Model (GMM) を用いる。

#### 3.4.2 文法を用いた HMM デコーディング

学習済みの HMM に対して Viterbi アルゴリズム [9] を適用し、テストデータにおける最も尤度の高くなる HMM 内/間の状態遷移系列を求める。推定された各時刻の HMM に対応するクラスが、動作・状態の推定結果となる。

本研究で用いる HMM は日常物の動作および状態のクラスごと用意されるため、Viterbi アルゴリズムはそれらをまたいだ状態遷移を求める。すなわち、あるクラスに対応する HMM の最後の状態から別のクラスに対応する HMM の最初の状態に遷移する。ここで、日常物の事前知識を用いて以下のような文法によって HMM 間の遷移を制限する。  
 $\dots \rightarrow \text{「開状態」} \rightarrow \text{「閉動作」} \rightarrow \text{「閉状態」} \rightarrow \text{「開動作」} \rightarrow \text{「開状態」} \rightarrow \dots$

これにより、例えば「開動作」から「閉状態」などの起こりえない遷移を制限できる。

## 4. 評価実験

### 4.1 データセット

本実験では三つの実験環境においてデータを取得した。実験を行った三つの環境と状態変化を推定する日常物の配置、Wi-Fi 機器の配置を図 6 に示す。また、実験に用いた日常



図 7 実験に用いた日常物  
Fig. 7 Everyday objects for experiment

物の一部を図 7 に示す。環境 1 のスクリーンは引き下げ式のものであり、引き下げられた状態を開状態とした。環境に設置する Wi-Fi 送信機には Buffalo WXR-2533DHP のアクセスポイント (AP) を用い、受信機には Intel 5300 NIC を搭載した PC を用いる。CSI データを取得するために PC に Halperin らによって改造された NIC のデバイスドライバをインストールする [29]。送信アンテナ数は  $N_T = 2$ 、受信アンテナ数は  $N_R = 3$ 、サブキャリア数は  $N_S = 30$  である。Wi-Fi の UDP パケットを AP から 1000Hz 程度で送信し、CSI を取得する。

各環境において、被験者は環境内を歩き回りながらそれぞれの日常物をランダムな順番で 1 回ずつ開閉し、これを 150 セッション行った。150 セッションの内 9 割をトレーニングデータ、1 割をテストデータとして 0.1 秒ごとに各日常物の状態を推定し、評価を行った。また、各時刻における日常物の状態 (正答) を取得するために、ビデオによる撮影を行った。

## 4.2 実験結果

### 4.2.1 提案手法による分類精度

提案手法による各日常物の状態推定結果の F 値を図 8 に示す。青丸が「開状態」と「閉状態」の平均 F 値を示し、オレンジの三角が「開動作」と「閉動作」の平均 F 値を示す。また棒グラフは全分類クラスにおける平均 F 値を示す。結果から、提案手法は F 値の平均が 85% と高い精度を達成していることが分かる。提案手法は窓とブラインドといった近い位置に存在する日常物や窓 1 と窓 2 といった同じ日常物の状態も高い精度で分類することができている。また、すべての日常物において動作の分類精度が状態の分類精度より低くなっている。これは動作にラベル付けされたデータが少なく、少しの推定誤りが精度に大きく影響してしまうためである。状態の分類精度は平均 96% を達成している。

### 4.2.2 比較手法による分類精度

比較手法として次に示す四つの手法を用いる。

- **w/o ICA**: CSI の前処理に ICA を用いない手法。CSI の振幅成分と位相成分のみを DNN に入力する。
- **w/o Grammar**: HMM のデコーディング時に日常物の事前知識に基づいた文法を用いない手法。




図 8 各日常物の状態分類精度  
Fig. 8 Classification accuracy for each object




図 9 各手法による推定精度  
Fig. 9 Classification accuracy for each method

- **w/o HMM**: 学習に用いた DNN の softmax 層の出力を推定結果とする手法。
- **RF**: CSI に対し PCA による次元削減を行い、Random Forest によって状態を推定する手法。特徴量として時間窓内の平均値、分散値、尖度、歪度、最大値、最小値、最大値と最小値の差を用いる。

提案手法と比較手法による日常物の状態推定精度を図 9 に示す。結果から、提案手法では ICA を用いることで 1~5% 程度、HMM と文法を用いることで 20~25% 程度の精度の向上が見られた。

提案手法と w/o Grammar, w/o HMM によって推定された環境 1 のドアに対する状態の時間推移の例を図 10 に示す。w/o HMM では推定結果に多くの突発的な推定誤りが存在することが分かる。提案手法では HMM を用いて推定結果を滑らかにすることで、この突発的な推定誤りを正すことができています。また w/o Grammar では開状態から開動作への遷移が起こっている。これはドアが開いている状態からさらに開くという現実では起こりえない変化である。提案手法では日常物の事前知識を用いることで現実では起こりえない状態遷移を修正することができています。

### 4.2.3 長期間データに対する分類精度の推移

時間経過による提案手法の推定精度の変化を調査するために、環境 2 において 1 日 20 セッションを 10 日間取得し、最初の 3 日間をトレーニングデータ、残りの 7 日間

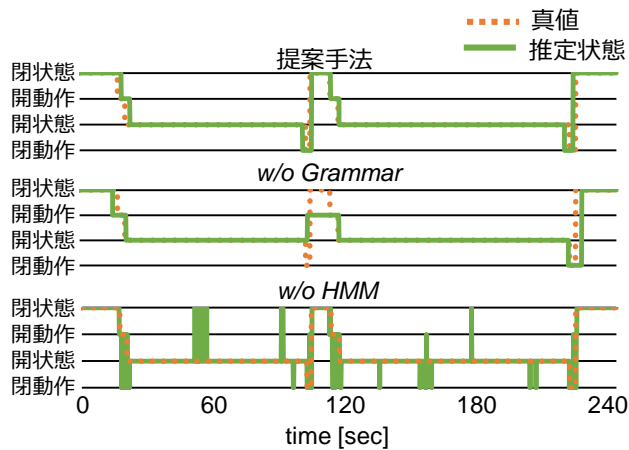


図 10 環境 1 のドアに対する各手法による推定状態の時間推移  
Fig. 10 Time transitions of states estimated by each method for door in environment 1




図 11 長期間データに対する分類精度の推移  
Fig. 11 Transitions of Classification accuracy

をテストデータとして評価を行った。日ごとの環境変化に対応するために、推定結果を疑似的な正答とみなして、Fine-tuning によって DNN のパラメータを日ごとに更新した。

各日に対する日常物の分類精度を図 11 に示す。6 日目以外の日では Fine-tuning を行うことで 2% 程度精度が向上している。6 日目に精度が低下したのは、6 日目（と 7 日目）に雨が降っていたからであると考えられる。電波伝搬は湿度に大きく影響されるため、6 日目のデータには他の晴れや曇りの日のトレーニングデータに含まれていない影響が存在したと考えられる。

#### 4.2.4 トレーニングデータ量による分類精度の推移

トレーニングデータ量による提案手法の推定精度の変化を調査するために、長期間データに対する評価の時にトレーニングデータを 3 日間から 1 日間まで減らし、評価を行った。

学習に用いる日数を変化させたときの分類精度の推移を図 12 に示す。結果から学習に 1 日間（20 セッション）や 2 日間（40 セッション）のデータを用いた時は 3 日間（60 セッション）のデータを用いた時と比較し大きく精度が低下していることが分かる。このことから提案手法において十分な精度を達成するには 60 セッション程度のトレーニング




図 12 学習に用いる日数を変化させたときの分類精度の推移  
Fig. 12 Transitions of Classification accuracy when the amount of training data is varied

表 1 人や椅子を追加した場合の平均 F 値

Table 1 Averaged F-measure when a person or chairs are added

	状態	動作	平均
一人椅子無し	0.976	0.760	0.868
二人椅子無し	0.913	0.729	0.821
一人椅子追加	0.884	0.680	0.782

ングデータが必要であると考えられる。提案手法は特徴量の抽出に Deep Learning 技術を用いているため、多くの学習データが必要となる。学習データやモデルを転移させる等のアプローチによってデータ収集の負担が少ない日常物の状態推定を実現することは今後の課題である。

#### 4.2.5 被験者、家具の追加による影響

環境内に複数人存在する場合の提案手法の有用性を調査するために、環境 3 において被験者を一人追加し、10 セッション収集した。追加された被験者は環境内を自由に歩き回った。また、家具を追加した時の影響を調査するために、環境 3 において椅子を四つ追加し、10 セッション収集した。

被験者が一人、椅子無しの時のデータによって学習したモデルを用いて日常物の状態を推定したときの平均 F 値を表 1 に示す。環境内に被験者が二人いる場合は一人の場合と比べて 4% 程度、椅子が追加された場合は椅子がない場合と比べて 8% 程度精度が低下した。しかし、状態に関する推定精度はどちらも 90% 近くあり、人や家具の追加によって電波伝搬環境の変化した場合でも、高い精度が実現できている。

## 5. おわりに

本研究では市販されている Wi-Fi 機器で取得できる Wi-Fi 電波の伝搬情報である CSI を用いて、ドアや窓の開閉といった屋内日常物の状態を推定する手法を提案した。CSI に対し ICA を用いることで各日常物の操作によって生じた CSI の変化に分離することを試みた。そして DNN を用いて自動的に抽出した有用な特徴量を HMM に入力することで日常物の状態を推定した。また日常物の事前知識に基

づいた文法によって HMM 間の状態遷移に制限を設けることで精度の改善を図った。

謝辞 本研究の一部は JST CREST JPMJCR15E2, JSPS 科研費 JP16H06539, JP26730047, JP17J06602, JP17H04679 の助成を受けて行われたものです。

## 参考文献

- [1] Philipose, M., Fishkin, K. P., Perkowitz, M., Patterson, D. J., Fox, D., Kautz, H. and Hähnel, D.: Inferring activities from interactions with objects, *Pervasive Computing, IEEE*, Vol. 3, No. 4, pp. 50–57 (2004).
- [2] Tapia, E. M., Intille, S. S. and Larson, K.: *Activity recognition in the home using simple and ubiquitous sensors*, Pervasive (2004).
- [3] Van Kasteren, T., Noulas, A., Englebienne, G. and Kröse, B.: Accurate activity recognition in a home setting, *Proceedings of the 10th International Conference on Ubiquitous Computing*, pp. 1–9 (2008).
- [4] Ali, K., Liu, A. X., Wang, W. and Shahzad, M.: Keystroke recognition using wifi signals, *Proceedings of the 21st Annual International Conference on Mobile Computing and Networking*, pp. 90–102 (2015).
- [5] Chapre, Y., Ignjatovic, A., Seneviratne, A. and Jha, S.: CSI-MIMO: An efficient Wi-Fi fingerprinting using Channel State Information with MIMO, *Pervasive and Mobile Computing*, Vol. 23, pp. 89–103 (2015).
- [6] LeCun, Y. and Bengio, Y.: Convolutional networks for images, speech, and time series, *The handbook of brain theory and neural networks*, Vol. 3361, No. 10, p. 1995 (1995).
- [7] Gers, F. A. and Schmidhuber, J.: Recurrent nets that time and count, *Neural Networks, 2000. IJCNN 2000, Proceedings of the IEEE-INNS-ENNS International Joint Conference on*, Vol. 3, pp. 189–194 (2000).
- [8] Ordóñez, F. J. and Roggen, D.: Deep Convolutional and LSTM Recurrent Neural Networks for Multimodal Wearable Activity Recognition, *Sensors*, Vol. 16, No. 1, p. 115 (2016).
- [9] Rabiner, L. R.: A tutorial on hidden Markov models and selected applications in speech recognition, *Proceedings of the IEEE*, Vol. 77, No. 2, pp. 257–286 (1989).
- [10] Campbell, B. and Dutta, P.: An energy-harvesting sensor architecture and toolkit for building monitoring and event detection, *Proceedings of the 1st ACM Conference on Embedded Systems for Energy-Efficient Buildings*, pp. 100–109 (2014).
- [11] Patel, S. N., Reynolds, M. S. and Abowd, G. D.: Detecting human movement by differential air pressure sensing in HVAC system ductwork: An exploration in infrastructure mediated sensing, *Pervasive Computing*, Springer, pp. 1–18 (2008).
- [12] Wu, M., Pathak, P. H. and Mohapatra, P.: Monitoring building door events using barometer sensor in smartphones, *Proceedings of the 2015 ACM International Joint Conference on Pervasive and Ubiquitous Computing*, pp. 319–323 (2015).
- [13] Shi, S., Sigg, S. and Ji, Y.: Passive detection of situations from ambient fm-radio signals, *Proceedings of the 2012 ACM Conference on Ubiquitous Computing*, pp. 1049–1053 (2012).
- [14] Sigg, S., Blanke, U. and Troster, G.: The telepathic phone: Frictionless activity recognition from wifi-rssi, *IEEE International Conference on Pervasive Computing and Communications (PerCom)*, pp. 148–155 (2014).
- [15] Abdelnasser, H., Harras, K. A. and Youssef, M.: Ubibreathe: A ubiquitous non-invasive wifi-based breathing estimator, *arXiv preprint arXiv:1505.02388* (2015).
- [16] Wu, K., Xiao, J., Yi, Y., Chen, D., Luo, X. and Ni, L. M.: CSI-based indoor localization, *IEEE Transactions on Parallel and Distributed Systems*, Vol. 24, No. 7, pp. 1300–1309 (2013).
- [17] Wang, Y., Jiang, X., Cao, R. and Wang, X.: Robust Indoor Human Activity Recognition Using Wireless Signals, *Sensors*, Vol. 15, No. 7, pp. 17195–17208 (2015).
- [18] Wang, W., Liu, A. X., Shahzad, M., Ling, K. and Lu, S.: Understanding and modeling of wifi signal based human activity recognition, *Proceedings of the 21st Annual International Conference on Mobile Computing and Networking*, pp. 65–76 (2015).
- [19] Han, C., Wu, K., Wang, Y. and Ni, L. M.: WiFall: Device-free fall detection by wireless networks, *INFOCOM, 2014 Proceedings IEEE*, pp. 271–279 (2014).
- [20] Zhang, D., Wang, H., Wang, Y. and Ma, J.: Anti-fall: A Non-intrusive and Real-Time Fall Detector Leveraging CSI from Commodity WiFi Devices, *Inclusive Smart Cities and e-Health*, Springer, pp. 181–193 (2015).
- [21] Liu, X., Cao, J., Tang, S. and Wen, J.: Wi-Sleep: Contactless sleep monitoring via WiFi signals, *Real-Time Systems Symposium (RTSS), 2014 IEEE*, pp. 346–355 (2014).
- [22] Zeng, M., Nguyen, L. T., Yu, B., Mengshoel, O. J., Zhu, J., Wu, P. and Zhang, J.: Convolutional neural networks for human activity recognition using mobile sensors, *Mobile Computing, Applications and Services (MobiCASE), 2014 6th International Conference on*, pp. 197–205 (2014).
- [23] Chavarriaga, R., Sagha, H., Calatroni, A., Digumarti, S. T., Tröster, G., Millán, J. d. R. and Roggen, D.: The Opportunity challenge: A benchmark database for on-body sensor-based activity recognition, *Pattern Recognition Letters*, Vol. 34, No. 15, pp. 2033–2042 (2013).
- [24] Yang, J. B., Nguyen, M. N., San, P. P., Li, X. L. and Krishnaswamy, S.: Deep convolutional neural networks on multichannel time series for human activity recognition, *Proceedings of the 24th International Joint Conference on Artificial Intelligence (IJCAI), Buenos Aires, Argentina*, pp. 25–31 (2015).
- [25] Hyvärinen, A.: Fast and robust fixed-point algorithms for independent component analysis, *Neural Networks, IEEE Transactions on*, Vol. 10, No. 3, pp. 626–634 (1999).
- [26] Ioffe, S. and Szegedy, C.: Batch normalization: Accelerating deep network training by reducing internal covariate shift, *arXiv preprint arXiv:1502.03167* (2015).
- [27] Kingma, D. and Ba, J.: Adam: A method for stochastic optimization, *arXiv preprint arXiv:1412.6980* (2014).
- [28] Srivastava, N., Hinton, G. E., Krizhevsky, A., Sutskever, I. and Salakhutdinov, R.: Dropout: a simple way to prevent neural networks from overfitting., *Journal of machine learning research*, Vol. 15, No. 1, pp. 1929–1958 (2014).
- [29] Halperin, D., Hu, W., Sheth, A. and Wetherall, D.: Tool release: gathering 802.11 n traces with channel state information, *ACM SIGCOMM Computer Communication Review*, Vol. 41, No. 1, pp. 53–53 (2011).