

状態推定のためのスパイクングニューラルネットワーク に基づくオンライン学習

Online Learning based on Spiking Neural Network for State Estimation

大保 武慶¹, 澤山 智之², 谷口 和彦³, ○久保田 直行¹

Takenori Obo¹, Toshiyuki Sawayama², Kazuhiko Taniguchi³, ○Naoyuki Kubota¹

¹ 首都大学東京

¹Tokyo Metropolitan University

² 日本医療機器株式会社

²Japan Medical Instruments Corporation

³ 株式会社きんでん

³Kinden Corporation

Abstract: Recently, it is expected that the number of elderly inpatients will increase more and more as Japan becomes an aged society. The introduction of monitoring system is one of the solutions for the problem. In our research, we focus on the monitoring using wireless sensor networks for the state estimation of elderly people in living room. In the previous research, many methods of human state estimation have been proposed. Most of the methods are based on off-line approach. However, huge data are required preliminarily in the off-line approaches for the modeling of the human states. Furthermore, the data values depend on the installation environment. Therefore, we discuss on-line learning methods for human state estimation. In this paper, we propose an on-line learning method applying spiking neural network as a learning architecture.

1. はじめに

現在、少子高齢化問題は大きな社会問題となっている。東京都保健局の調査では、都内の65歳以上の高齢者の数も、10年後には300万人（都民の1/4）を超えると予想され、独り暮らしの高齢者も今後さらに増えていくとされている。そのため、在宅介護も含め、介護支援を目的とした高齢者の見守り支援システムの研究開発は急務である。

近年では、情報技術やネットワーク技術の発展に伴い、様々な介護支援システムの開発がなされている。例えば、高齢者の早期救済を目標とした緊急通報システムがその一例であり、体調の急変や転倒を自動判定・通報を目的とした、ウェアラブルセンサなどの開発が行われている。また、高齢者の行動計測を目的とした身守りシステムもその一例である。さらに近年では、ロボット技術を応用した事例も提唱されており、人間と共生する情報システムとして研究開発が進められている。本研究でも、パートナーロボットを適用し、高齢者の認知機能の活性化を目的とした見守りロボットシステムの研究開発を行ってきた[1]。

これらの機械的支援は、介護者の負担を軽減していくことが主目的となる。そのため、高齢者の状態

をリアルタイムに把握する技術が要望されている。人間の状態推定に関する方法論は多く提唱されているが、ほとんどがオフライン処理に基づくものである。しかしながら、実世界における人間の状態はきわめて多様であり、これらを全てモデルすることは現実的ではない。そのため、収集されたデータの関係性を、適宜、更新・学習しながら、ものや人の状態といった、高次的な情報を抽出する方法論が必要とされる。

一方、高齢者を取り巻く環境において、高齢者が注意を払っている対象の知覚や、高齢者が扱う道具などを考慮することにより、よりきめの細かい見守りが実現できることが考えられる。このような議論を行う上で、役に立つのが身体性の概念である。身体性を拡張する方法論としては、(1) 物理的な道具などによる拡張、(2) 人間やロボットなどの自律的な他者による拡張、(3) インテリジェントルームなどの空間自体による拡張などが考えられる。これらの「道具」、「他者」、「空間」は、人間にとって使いやすい存在でなければならない。そのため、逐次的な「学習」や「適応」の考え方が重要となる。

本研究では、人間とカップリングされた環境において、適応的に人間の状態パターンを学習し、見守り

支援を実現することを目的に、住環境にセンサネットワークを適用する。また、人間の行動に伴う、各種センサ値の変化から人間の行動パタンの学習・予測を目的としたオンライン学習アルゴリズムの提案を行う。以降、2章では、提案手法である学習アルゴリズムについて説明する。また、3章では、システムについて説明し、4章では、提案手法の適用方法について説明する。さらに、5章では、提案手法の有用性を検証するための実験結果を示し、最後に、6章にて、本論文のまとめを述べる。

2. 学習アルゴリズム

2. 1 スパイクングニューラルネットワーク

脳の神経細胞は細胞の内部電位が閾値を超えたときに数ミリ秒の短い時定数を持つ急激な電圧変動を発生させる。これはパルスあるいはスパイク発火と呼ばれ、脳内ではこのスパイクの集合が細胞間や細胞群間で交換されることで、情報が表現されている。

McCulloch と Pitts の二値型離散モデルに代表されるように、ニューロンモデルは工学的応用において有用な性質の一部のみを用いて単純化されて設計されている。そこでは生体の神経細胞の特徴の多くがモデル化されているが、実際の脳内のニューロンの応答特性はより複雑なダイナミクスを持つ。パルスニューロンモデル (Pulsed Neuron, Spiking Neuron Model) は、パルス入力による神経細胞の内部状態の変化を実際の生体反応に近い形で模式化するものであり、一般的な積分器型のモデルよりも詳細な手法である。従来のニューロンモデルの多くは、スパイクの時間平均で情報を表現しており、一つ一つのスパイクに大きな意味はないという仮定をもとしているが、パルスニューロンモデルは、一つのスパイクの有無あるいは一つのスパイクの発火タイミングに基づきネットワークの振る舞いに変化するようなモデルを構成することができる。

スパイクングニューラルネットワーク (Spiking Neural Network; 以下, SNN) はパルスニューロンモデルに基づく時系列処理能力に優れた学習構造の一つである。現在までに提案されているパルスニューロンモデルは近似の粒度によって多数あるが、本研究

における SNN の構成式は以下ようになる。

まず、 i 番目のニューロンの内部状態を表す内部膜電位を $h_i(t)$ とし、式 (1) のように計算する。

$$h_i(t) = \tanh(h_i^{syn}(t) + h_i^{ext}(t) + h_i^{ref}(t)) \quad (1)$$

ここで、双曲線余弦関数はニューロンの過剰発火であるバースティングを抑制するために適用している。また、 $h_i^{ext}(t)$ は i 番目のニューロンへの外部環境からの入力値であり、 $h_i^{syn}(t)$ は他のニューロンからの入力によって発生した電位の総和である。 $h_i^{syn}(t)$ は、以下の式 (2) ように、他ニューロンからの入力と内部状態との和に基づき更新される。

$$h_i^{syn}(t) = \gamma^{sys} \cdot h_i(t-1) + \sum_{j=1}^N w_{j,i} \cdot h_j^{PSP}(t-1) \quad (2)$$

$w_{j,i}$ は i 番目のニューロンから j 番目のニューロンへの結合強度、 $h_j^{PSP}(t)$ は離散時間 t における j 番目のニューロンからのシナプス前繊維末端の活動電位である。 N はニューロンの総数を示し、 γ^{syn} は減衰項である。ニューロンの内部膜電位はある閾値を超えると神経発火を起こす。神経発火の有無を $p_i(t) \in \{0, 1\}$ とすると、以下の式 (3) によって表現できる。

$$p_i(t) = \begin{cases} 1 & \text{if } h_i(t) \geq q_i \\ 0 & \text{otherwise} \end{cases} \quad (3)$$

q_i は神経発火の閾値である。さらに、 $h_i^{ref}(t)$ はニューロンの不応期を表現する項であり、以下の式 (4) のように定義される。

$$h_i^{ref}(t) = \begin{cases} \gamma^{ref} \cdot h_i^{ref}(t-1) - R & \text{if } p_i(t-1) = 1 \\ \gamma^{ref} \cdot h_i^{ref}(t-1) & \text{otherwise} \end{cases} \quad (4)$$

ここで、 $R > 0$ であり、発火のあった時間からある一定時間のニューロンの発火を抑制する。なお、 γ^{ref} は減衰項を示す。

シナプス前繊維末端の活動電位はシナプス後電位 (postsynaptic potential; PSP) に基づくニューロン間の結合関係によって伝搬される。PSP は式 (5) によって計算される。

$$h_i^{PSP}(t) = \begin{cases} 1 & \text{if } p_i(t-1) = 1 \\ \gamma^{PSP} \cdot h_i^{PSP}(t-1) & \text{otherwise} \end{cases} \quad (5)$$

γ^{PSP} は $0 < \gamma^{PSP} < 1$ の減衰項である。ニューロン間の結合重みである $w_{j,i}$ が正の場合、シナプス後電位は興奮性電位としてはたらく。また、 $h_i^{PSP}(t) > h_j^{PSP}(t)$ が成

立する場合には、以下の式 (6) に基づくヘブ学習 (Hebbian learning) により、ニューロン間の結合強度 $w_{j,i}$ が更新される。

$$w_{j,i} \leftarrow \gamma^{wgt} \cdot w_{j,i} + \xi^{wgt} \cdot h_j^{PSP}(t) \cdot h_i^{PSP}(t) \quad (6)$$

2. 2 階層型学習構造

前節で述べたように、SNN はヘブ学習に基づき、時空間的な文脈の学習が可能な学習構造である。しかし、上記のアルゴリズムには、学習された重みは逐次更新されるため、過去に学習された情報は忘却されてしまうという問題点がある。そのため、必要とされる情報が抽出された場合には、これを長期的な記憶として保持し、必要に応じて再起可能な学習構造が必要となる。また、保存された情報は、単に蓄えるだけではなく、再起性の高い情報はより長期的に保持しやすく、低い情報は忘却しやすくすべきである。本研究では、SNN の相互結合強度を短期記憶として学習する下位層と、SNN の発火状態を長期記憶として学習する上位層により構成される階層型学習構造を構築する (Fig. 1)。

学習構造は 2 階層からなるものの、初期段階においては、上位層にはニューロンは存在しない。上位層のニューロンは、下位層のニューロンの発火パターンを入力として、学習の進行に伴い増殖していくものとする。提案手法では、長期記憶において既に学習された発火パターンと、下位層における各ニューロンの発火パターンを比較することにより、(1) ニューロンの追加処理、(2) 学習処理のいずれかを行う。

まず、ニューロンの追加処理について述べる。ここでは、新たに追加するニューロンを m 番目として、学習する結合重みベクトルを W_m とすると、追加学習されるニューロンは以下のように更新できる。

$$H^{STM} = \{h_1^{PSP}(t), h_2^{PSP}(t), \dots, h_N^{PSP}(t)\} \quad (7)$$

$$W_m = H^{STM} \quad (8)$$

H^{STM} は入力ベクトルを示す。本提案手法では、発火に伴いニューロン間に残存するシナプス後電位 $h_i^{PSP}(t)$ に着目し、これを入力ベクトルとする。初期状態において、上位層にニューロンが存在しない場合は、式 (8) に基づき、ニューロンが追加される。一方、長期記憶において既知となるニューロンが構

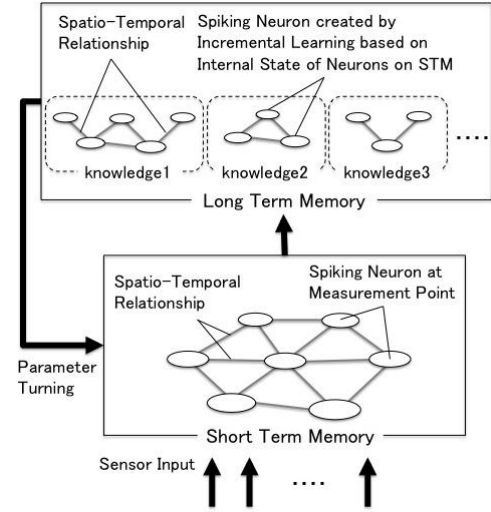


図 1 階層型学習構造

築されている場合は、入力ベクトルに対する学習を行う。入力ベクトルに対して、最もユークリッド距離の近い勝者ベクトルを i 番目のニューロンと仮定すると、長期記憶は、以下のように更新される。

$$d_i(t) = \|H^{STM} - W_i\| \quad (9)$$

$$W_i = \begin{cases} H^{STM} & \text{if } d_i(t) > D \\ \alpha_i \cdot W_i + (1 - \alpha_i) \cdot H^{STM} & \text{otherwise} \end{cases} \quad (10)$$

$$\alpha_i = 1 - \frac{\beta}{a_i + 1} \quad (11)$$

$d_i(t)$ は、勝者ベクトルから入力ベクトルまでのユークリッド距離であり、 D は追加学習における距離の閾値である。また、式 (11) は学習を行う場合の学習率の更新式を示す。ここで、 α_i は学習率、 β は任意の係数であり、 a_i は勝者ベクトルからあるユークリッド距離の範囲内に存在する上位層のニューロン数を示す。式 (11) は、学習の進行に伴い、学習率を変更することで分類学習の向上を目的とする。

3. システム構成

本研究では、人間の状態計測を目的とし、住環境にセンサネットワークを適用する。一般的に、人間の生活空間は家具や家電が日々の生活の中で移動することなどが頻繁に生じる動的な環境である。そのため、カメラなどによる大域的な計測だけでは死角が生じやすく、家具などにセンサを取り付けた局所的な計測だけでは人間の状態を把握しきれないとい

った問題がある．そこで，本研究で適用するセンサネットワークは，大域的計測と局所的計測の相補的な構成を目的とする．図3にシステム全体図の一例を示す．ここでは，大域的計測に，人間の位置推定を目的として，レーザレンジファインダを適用し，局所的計測には，各家具の使用状態などの観測を目的として，高感度の小型圧力無線センサを適用する．小型圧力センサは，大気圧の計測が可能なセンサであり，人の移動やドアの開閉などに伴う圧力の変化を検出する．また，ベッドなどには，感圧部分がマット式の圧力センサを適用することで，寝返りなどの就寝状態の計測を行う．




図2 住環境におけるセンサネットワーク

4. 状態推定のためのオンライン学習

2章では，本提案手法において適用する学習手法について述べたが，本章では，大域的計測，局所的計測において，人間の行動に伴い取得された各種センサデータから互いの関係性を学習する方法論について述べる．

本提案手法では，各種センサの計測点に対して，SNNの各ニューロンを構築する．図3にはその概念図を示す．大域的計測では，レーザレンジファインダの計測領域内において分割領域を設け，個々の分割領域内の一つずつニューロンを配置している．ここでは，各々の領域内において，距離値の差分値をニューロンへの入力値としている．また，局所的計測では，各種センサ，一つずつにニューロンを設け，各々において得られるセンサ値に基づきニューロンへの入力を与える．ここで， i 番目のセンサにおける

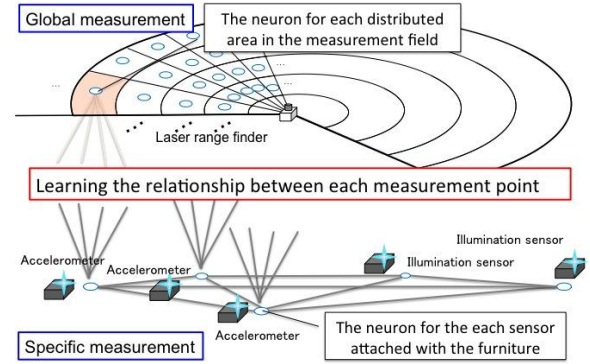


図3 大域的計測・局所的計測に基づく学習構造

j 番目の計測点のセンサ値を $v_{ij}(t)$ とし，各種センサにおける基準値を $V_{i,j}$ とすると，各ニューロンへの入力値は以下の式 (12) によって求められる．

$$h_{s,i,j}^{ext}(t) = \min \left\{ \alpha \cdot (v_{i,j}(t) - V_{i,j})^2, 1 \right\} \quad (12)$$

ここで， α は重み係数である．入力値は，センサ値と基準値のユークリッド距離によって求められる．また，基準値の更新率を ξ^{sen} とすると，基準値は以下の式 (13) によって逐次更新される．

$$V_{i,j} \leftarrow (1 - \xi^{sen}) \cdot V_{i,j} + \xi^{sen} \cdot v_{i,j}(t) \quad (13)$$

日常生活の営みがある住環境では，人間と環境との相互作用により環境は常に動的に変化し続けることが考えられる．そのため，ここでは，環境に対して基準値を適応させるため式 (13) を適用する．

以上より，人間による家具の使用または移動や，人間の歩行などが計測され，各々のニューロンが発火することで，各計測点のニューロン間の結合関係が学習される．ここで学習された関係性は，式 (2) に示すように，発火における他ニューロンへの外部出力に適用され，次状態への予測を実現する．このような学習や予測の機能は，実環境のような無限の広がりを持つ空間に対して，システムが対象とすべき領域を限定するために有効な働きを持つ．本提案手法において SNN を適用する理由は，各種センサデータを正規化し，時空間的な文脈の学習を実現する，このような学習特性にある．また，各々のニューロンの内部状態を保持しているため，単純な入力値の上昇では発火しない耐ノイズ性を有していることも適用理由の一つである．

5. 実験

提案した学習構造の実装およびその有用性を検証するため、住環境における人間の行動計測実験を行った。住環境には、各種センサが取り付けられており、局所的計測では、ドア、ベッド、衣装ケース、椅子、冷蔵庫の5カ所にセンサを配置し、大域的計測では、レーザレンジファインダを、対面する壁にあわせて、2台向かい合わせて配置した。以下、図4に実験環境の概略図を示す。

一方、SNNの構造に関して、局所的計測において、各計測点に用意するニューロンの数は5つである。これらのニューロンは、(1) ドアでの入退室、(2) 椅子における離着席、(3) ベッドにおける離床・起床、(4) 衣装ケースや(5) 冷蔵庫の利用、といった各家具の使用状態を検出するために適用する。また、大域的計測では、4章でも述べたように、分割領域に各ニューロンを構築していく。ここでは、人間の移動などに伴う行動パターンを学習することを目的とする。




図4 実験環境概略図

5. 1 SNNに基づく関係性の学習結果

図5に、局所的計測における5つのニューロンの内部パラメタの時間的推移を示す。図5中、各グラフの青線は各ニューロンへの入力値、赤線は内部状態およびシナプス後電位の時間的推移を示す。図5に示す実験結果は、起床から朝食に至るまでの行動を計測した際のものである。ここでは、まず、人間は、(A) ベッドから起床し、(B) 着替えるために衣




図5 SNNの内部状態の時間的推移

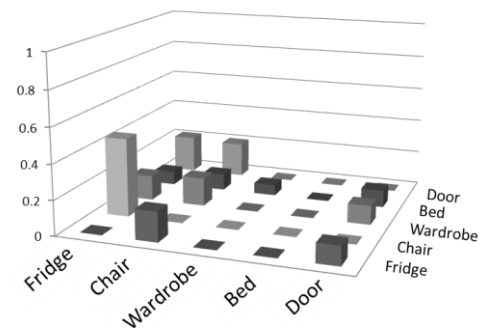


図6 SNNにおける関係性の学習結果




図7 大域的計測点における各ニューロンの発火

装ケースに向かっている。その後、(C) トイレに向かうために部屋を出て行き、(D) 椅子に着席する。そして、(E) 最後に朝食を取りに行くために冷蔵庫に向かい、椅子へ戻って朝食を食べている。図5中 (A) では、人間がドアから入室し、椅子に着席する過程から、ドアおよび椅子に対応するニューロンが発火していることが確認できる。これらの発火パターンは、教師なし学習の一手法であるヘブ則に基づき学習される。図6には、学習結果に基づく各ニュー

ーロン間の結合強度を示す。また、図 7 には、大域的計測における各ニューロンの発火の様子を示す。左図の青円が人間の検出位置を示しており、青線が人間の移動経路である。ここでは、人間の移動に伴いニューロンが発火している様子が右図の赤い矩形領域にて確認できる。これらニューロンの発火により学習される結合強度は、計測される人間の状態によって逐次更新され、状態パタンの抽出などに適用すること可能である。

5. 2 階層型学習に基づく状態パターン抽出

2.2 節で述べたように、SNN は、学習された重みが逐次更新されるため、過去に学習された情報は忘却されるという問題点がある。これは、学習における、安定性と可塑性のジレンマとよばれる特性である。そこで、次に、SNN の発火パターンを人間の状態パターンとして記憶するために、本提案手法である階層型学習構造を適用して実験を行った。図 8 は、就寝至る前、およそ 20 分間の人間の状態の記録であり、図 9 は、局所的計測点における各ニューロンの発火の時間的推移を示している。図 9 より、各状態の変わり目において各ニューロンが発火している様子が確認できる。また、図 10 には、長期記憶の追加学習に基づくニューロン数の推移の様子を示す。ここでは、学習初期の段階では急激にニューロン数が増加するが、再起性のある情報に関しては追加処理がなされていない様子が確認できる。例えば、0～500[Step]の間では、入室や着席、冷蔵庫の利用などが、新しい状態パターンとして学習されているが、それ以降の 1000～3000[Step]において同様の動作がなされていても、ニューロンの増加がないことがわかる。

6. おわりに

本稿では、人間の状態推定を目的とし、SNN の時系列処理能力に着目したオンライン学習構造を構築した。実験では、SNN の内部状態の変化に基づき重みが更新され、それぞれの情報の関係性が学習されることを示した。また、階層型学習構造を適用することで、相互結合型の SNN の発火のダイナミクスを長期記憶として記憶できることを示した。今回、




図 8 実験時における人間の状態推移




図 9 局所的計測点における発火ニューロンの推移




図 10 追加学習処理に基づくニューロン数の推移

抽出すべき人間の行動は単純なものであったが、実際の人間の行動パターンはもっと多様なものである。そのため、今後の課題としては、学習の進行に伴う学習率の最適化手法などを考えていく予定である。

参考文献

- [1] T.Obo, N.Kubota, Beom Hee Lee: Localization of Human in Informationally Structured Space Based on Sensor Networks, Proc. of 2010 IEEE World Congress on Computational Intelligence (WCCI 2010), pp.2215-2221, 2010.

連絡先

〒191-0065 東京都日野市旭が丘 6-6
首都大学東京 大保 武慶
E-mail: oobo-takenori@sd.tmu.ac.jp